

節 2 / 共 4 節

Harness Engineering

怎麼把 agent 調成我要的形狀？

節 1 只用到了 context 的第一種來源

這一節接上第二、第三種。

已經知道的

- LLM 是在猜，會流暢地講錯
- 它只看得到 context —— 但 agent 會自己去填
- 四個層次：prompt / context / **harness** / loop

已經做到的

- agent 跑起來了
- 看清楚了它自作主張什麼

這一節要接上的

節 1 用的是第一種：當下打的字。

- **常駐的設定檔** → 開機就知道規矩
- **工具抓回來的** → 能碰到外部系統
- **自動被檢查** → 做完就驗

模型是你選的， harness 是你做的。

你不能控制模型腦袋裡發生什麼，但你可以完全控制它能碰到什麼、做完要通過什麼檢查。

2-A

Harness 全景圖

一個 agent 由哪些零件組成？

一個 agent 拆開來長這樣

初始輸入檔

每次都載入的規
矩

Skills

用到才載入的
SOP

Tools / MCP

真的去執行的手
腳

迴路 / 守衛

做完自動檢查、
危險的事前擋下

Subagents

分身去做髒活
(附錄)

↑ 以上全部都是你寫的

↓ 這個你只能選，不能改

模 型

這些零件的差別，只有三個維度

零件	何時載入	誰執行	能不能強制
初始輸入檔	每次	模型自己	✗ 只是請求
Skill	用到才載入	模型自己	✗ 只是請求
Tool / MCP	每次（工具清單）	外部系統	✓ 做了就是做了
迴路（事後）	做完之後	你的腳本	✓ 沒過就叫它重做
守衛（事前）	工具執行前	你的腳本	✓ 根本不讓它跑

重點 最右邊那一欄是這一節最重要的分野。前兩個是「拜託模型」，後兩個是「程式強制」。

2-B

初始輸入檔

CLAUDE.md / AGENTS.md 與 rules

專案的規矩，每次對話都要重講一遍

「這專案用 pnpm、註解寫繁中、不要用 any」

—— 開新對話，再打一次

初始輸入檔＝每次都會自動載入的一段話

- agent 啟動時會**自動讀進 context** 的檔案
- 等於「你不用每次重打的那段話」

Prompt	當次 context —— 這次要做什麼
初始輸入檔	持久 context —— 這個專案永遠的規矩

實務 這是 context engineering **最便宜的落地方式**：寫一次，之後每次對話都自動生效。

同一個概念，每個工具取不同的名字

這就是所謂「rules 功能不一樣」的真相。

工具	檔名	特性
Claude Code	CLAUDE.md	也讀 AGENTS.md；支援全域 / 專案 / 子目錄分層
Codex、Cursor 等	AGENTS.md	跨工具的事實標準，最多人用
我們今天用的 pi	兩個都讀	全域 → 各層父目錄 → 當前目錄；AGENTS.override.md 會 取代 而非疊加
其他	.cursorrules 等	各家自訂

重點 概念完全相同，實作各家不同。要記的是「有一個檔案會被自動載入」，不是某個檔名。

實務作法：單一真實來源

- 用 AGENTS.md 寫**唯一一份**內容
- 其他工具要的檔名，寫一行指過去就好

See @AGENTS.md

CLAUDE.md 的全部內容

注意 不要維護兩份。兩份一定會不同步，然後你會花一個下午 debug 「為什麼這個工具聽話另一個不聽」。

作用域：三層，範圍越小越優先

層級	放什麼	例子
全域（你的家目錄）	我個人 的習慣，跨所有專案	回答用繁體中文、先講結論
專案根目錄	這個專案 的規矩	用 pnpm、禁止 any、測試怎麼跑
子目錄	這個模組 的特例，進到該目錄才載入	legacy/ 底下不要重構

重點 衝突時，**範圍越小的贏**。跟 CSS 的 specificity 是同一個直覺。

實務 **Lab 2 進階題** 三層都寫一份、故意讓它們打架，實測到底誰贏。

該寫什麼

- ✓ **怎麼跑測試、怎麼 build** —— 最常被猜錯的一項
- ✓ **非顯而易見的慣例** —— 「我們的 API 一律回 snake_case」
- ✓ **專案術語** —— 「訂單」指的是 PurchaseOrder，不是 Order
- ✓ **明確的禁止事項** —— 「不要動 migrations/」 「不要自己加套件」

實務 判斷法則：新同事第一天上工會口頭交代的，就該寫進去。

不該寫什麼

- **X 程式碼結構** —— 它自己讀得到，而且你寫的很快就過期
- **X git log 查得到的東西** —— 改動歷史、誰改的、為什麼
- **X 專案背景故事** —— 「本專案源於 2023 年的一場討論…」
- **X 行銷語言** —— 「我們致力於打造世界級的…」

注意 每一行都佔 context，而且每一次對話都佔。寫成 500 行不會讓它更聽話，只會稀釋它對真正重要那幾條的注意力。

AGENTS.md 不是 README。

它是給新同事的交接便條。

交接便條是「你會踩到的坑在這裡」，不是「本專案簡介」。

起手式：讓它自己寫一份

- Claude Code / Codex 有 `/init`，掃過專案生成初版
- pi 沒有這個指令，直接叫 agent 掃一遍寫一份也一樣
- **但一定要人工砍掉一半** —— 它生出來的多半是程式碼結構摘要，正是不該寫的那類

它生成的	你該做的
50 行專案結構描述	全部刪掉
「使用 TypeScript 開發」	刪掉，它看得到
「測試指令： <code>pnpm test</code> 」	留著，這才是重點

最重要的一課

你寫了，**不代表它會照做**。

- 能力較弱的模型（例如我們今天用的免費模型）尤其如此
- 規則越多，被忽略的機率越高
- 你**沒有辦法**從它的回覆判斷它有沒有遵守，只能檢查產出

重點 所以下一個問題是：**能不能用程式強制？** → 那是 2-F 的迴路與守衛。先把「拜託模型」這一半講完。

2-C

Skills

用到才載入的做事說明書。

Skill 是用到才載入的說明書

- 一包「做某件事的 SOP」，可能還附腳本
- **用到才載入**，平常不佔 context
- 用 `/skill:name` 呼叫

注意 pi 只常駐 skill 的**描述**，全文靠模型自己去讀——而它**不一定會讀**。今天一律用 `/skill:` 明確呼叫。

適合寫成 skill 的	例子
偶爾才跑一次的流程	產生本專案格式的 commit message
步驟多、需要照順序	發版流程：改版號 → 更新 changelog → 打 tag
有固定產出格式	寫一份符合公司樣板的技術文件

初始輸入檔 vs Skill

	初始輸入檔 (AGENTS.md)	Skill
載入時機	每次 都載入	用到才 載入
context 成本	持續佔用	平常是 0
適合	一直都要遵守的約束	偶爾才跑一次的流程
判斷法則	「每次都要」	「偶爾才做」

實務 直接的推論：**AGENTS.md 太長的時候，把偶爾用到的部分抽成 skill。** 這是實務上最常見的一次重構。

2-D

Lab 2 : AGENTS.md + Skill

寫規範，然後量它到底聽不聽話。

Lab 2 AGENTS.md + Skill

60 分鐘

目標 親手證明「有沒有寫規範」會產生不同的程式碼，以及「寫了也不一定照做」。

素材： labs/lab2-agents-md/grades/ —— 能跑但很醜的成績計算工具，只有兩個檔。

1. **基準** 不給任何規範，讓 agent 重構。記錄它自作主張了什麼
2. **加約束** 寫一份 AGENTS.md，用**完全相同的指令**再跑一次，比較兩份 diff
3. **測遵守率** 同一份 AGENTS.md 連跑 3 次，統計每條規則被遵守幾次
4. **抽成 skill** (進階) 把「產生 commit message」寫成 skill，用 /skill: 強制呼叫

注意 步驟 3 如果遵守率不是 100% —— **這不是 lab 失敗，這正是本 lab 要教的事。** 把數字記下來。

Lab 2 記錄表

步驟 3 的統計。這張表的數字，Lab 4 會用到。

規則	起始	第 1 次	第 2 次	第 3 次
R1 禁止使用 any	5			
R2 匯出函式小駝峰、動詞開頭	1			
R3 組字串用 template literal	5			
R4 魔術數字要抽成常數	7			
R6 匯出函式要有一行說明	2			
R5 註解要說明「為什麼」	人工看			

`node ../lab4-loop/check.ts` 會幫你數前五條。

重點 等一下 Lab 4，我們要用迴路把這幾個數字壓下去。

2-E

工具

從它本來就有的，到你自己接上去的。

它本來就有的工具，先用好

很多「模型不知道」，其實是「你沒讓它去查」。

讀檔	Cargo.lock、package.json —— 實際裝的版本 ，不是它記得的版本
跑指令	cargo check、npm view、跑測試 —— 結果是事實 ，不是回憶
搜尋網路	新套件、改過的 API、昨天發的 release

重點 節 1 地圖的第一列（版本落後、API 搬家），**靠這三件事就解掉了**。

注意 所以「換更強的模型」通常不是答案。**答案是讓它去查**。

MCP 是接到外部系統的標準插頭

內建工具碰不到的東西，用 MCP 接。

- 一個**標準插頭**，讓 agent 能接到**內建工具碰不到**的系統
- 資料庫、瀏覽器、公司內部 API、檔案系統、雲端服務…
- 重點在「**標準**」：寫一次 server，所有支援 MCP 的工具都能用

重點 前面兩節講的（初始輸入檔、skill）都是「**說給模型聽**」。MCP 是第一個「**真的會去執行**」的東西。

注意 真的會執行 = 真的會出事。接上一個能改資料庫的 MCP，就等於給了 agent 改資料庫的權限。

Skill vs MCP：實務上到底怎麼選

	Skill	MCP
本質	一段「怎麼做」的說明	一個「能做什麼」的連線
誰執行	模型照著做	外部 server 真的去執行
要不要跑服務	不用	要（本機或遠端）
適合	流程、規範、產出格式	存取外部狀態、需要權限的操作
成本	幾乎 0	連線、維護、資安
判斷法則	只是教它怎麼做	它需要碰到外面的東西

實務 被問爛的問題「這個該做成 skill 還是 MCP？」→ 看最後一列就好。

MCP 在 pi 上要怎麼用？

這一頁是「概念相同、實作各異」最好的例子。

pi 官方明文寫著：它**刻意不內建** MCP、subagent、permission popup、plan mode。

- 這不是缺陷，是設計取捨：核心極小，其他靠 extension
- **「這個功能怎麼用」取決於手上是哪個工具**

實務 現在 看我 demo 一次：agent 接上工具後多了什麼能力。

重點 課後 附錄有完整設定檔與 registerTool 骨架。

今天沒有 Lab 3，下一個動手是 Lab 4。

2-F

Loop Engineering

取代「一直按 enter 的那個人」。

一個迴路只有三個零件

設計迴路，就是決定這三件事。

	等一下的 Lab 4	「把題目全解完」的迴路
工作從哪來	就這一個重構任務	題目網站上還沒解的題
每一輪做什麼	改 → 跑檢查 → 錯誤餵回去	挑一題 → 解 → 送出 → 看結果
什麼時候停	檢查過了，或重試 3 次	清單空了

重點 最容易被忽略的是最後一列。沒有明確的停止條件，agent 會一直跑下去 —— 或者一輪就停在你沒預期的地方。

注意 停止條件必須**客觀可判定**：編譯過了、測試綠了、清單空了。「做得夠好了」不算。

Lab 4 讓它自己修錯

30 分鐘

目標 把 Lab 2 那張表裡「機器檢查得到」的規則，遵守率明顯拉上去。

問題回顧：AGENTS.md 明明寫了「禁止 any」，它還是用了。

```
./loop.sh "把 calc.ts 與 report.ts 依照 AGENTS.md 重構"
```

loop.sh 約 50 行，核心就這四步：

```
run_agent "$TASK" # 做
OUT=$(node check.ts "$TARGET") && exit 0 # 檢查
run_agent "違規如下：$OUT 請修好" continue # 餵回去 → 再做
```

重點 驗收 你能展示錯誤訊息被**自動**餵回去，而且遵守率明顯上升。

Lab 4 的第二個問題（比第一個重要）

check.ts 實作了 R1、R2、R3、R4、R6 —— 唯獨沒有 R5。為什麼？

規則	程式擋得住嗎
R1 禁止使用 any	✓ grep 就抓得到
R3 組字串用 template literal	✓ grep
R2 匯出函式命名	✓ 一行 regex
R4 魔術數字要抽成常數	勉強 會有誤判
R5 註解要說明「為什麼」	✗ 沒有任何 linter 擋得住

重點 能被程式檢查的規則，才能被強制。設計規範時就要往「可被檢查」的方向設計。

實務 進階 見下一頁：有些事情**不能事後修**。

有些事情不能事後修

它把`.env`讀出來貼到某個地方之後，你修不回來。

	loop.sh (事後)	守衛 (事前)
何時介入	agent 整輪跑完後	工具執行前
能不能阻止	不能，只能叫它改	能，根本不讓它跑
適合	品質問題：風格、型別	安全問題：機密、刪檔、對外送出的

```
pi.on("tool_call", async (event) => {           // 執行「前」
  if (findSecretRef(event.input))
    return { block: true, reason: "改讀 env.sample" };
});
```

重點 判斷法則：**修得回來的用事後，修不回來的用事前。**

守衛也是程式，也會有洞

這是進階組今天最好玩的十分鐘。

guard/env-guard.ts 第一版的樣式是這樣寫的：

```
/(^|[/\]\])\.env(\.|$)/i // 要求 .env 前面是斜線或開頭
```

然後 `cat .env | head` **直接穿過去** ——
因為在 shell 指令裡，`.env` 前面是**空格**，不是斜線。

- guard/test.ts 裡有 10 種攻擊寫法，其中兩種就是這樣漏掉的
- **你的任務：再想幾個繞法出來**

重點 守衛沒有測試，你不會知道它漏了什麼 —— 而且**不會有任何錯誤訊息告訴你**。

Prompt 是請求。

迴路是強制。

跟安全、跟品質有關的規則，用迴路擋。不要用拜託的。

2-G 小測：這六件事該用哪個零件？

舉手。四個選項：初始輸入檔 / skill / 工具 / 迴路。

	情境	答案
1	每次 commit 訊息都要用中文	
2	要查公司內部的訂單資料庫	
3	絕對不能碰 prod/ 目錄	
4	每季做一次的資安稽核流程	
5	產出必須通過型別檢查	
6	專案的術語表	

重點 答完之後，我們把 2-A 那張「何時載入 / 誰執行 / 能不能強制」的表**當場填滿**。

附錄 Subagent / Agent team / Workflow

只講不做。講義附錄有可以課後自己跑的範例。

	做什麼	什麼時候用
Subagent	把獨立的髒活丟給分身做	不想讓一堆搜尋結果污染主對話
Agent team	多個角色分工：寫的、找 bug 的、驗證的	需要互相檢查 的時候
Workflow	寫死的流程，不讓模型自由發揮	需要可重現、可稽核、控成本

重點 Workflow 的判斷法則值得記：當「每次結果都一樣」比「每次都很聰明」更重要時，就寫死流程。

注意 pi 核心沒有內建 subagent，要靠 extension 或開多個 instance —— 又一個「概念相同、實作各異」的例子。

agent 現在知道專案的規矩了

節 2 小結

本節重點

- agent 由五種零件組成
- 初始輸入檔＝持久 context
- AGENTS.md 不是 README
- skill 按需、初始輸入檔常駐
- 工具與 MCP 是真的會執行
- **prompt 是請求，迴路是強制**

明天：它還不知道的事

- 社團的內部規定
- 公司的內部文件

以及：怎麼把這一切**放進真的產品裡**。

實務 節 1 那個被編出來的答案，明天把它救回來。